

Análisis de series temporales de resultados de inspecciones de mataderos

- Una nueva herramienta para la higiene de la carne utilizando la epidemiología -

Yasuki Adachi*

Estación de Inspección Sanitaria de Carne de Hayakita, Hokkaido

Análisis de series temporales de resultados de inspección de carne

—Una nueva herramienta para promover la producción higiénica de carne

Basado en la epidemiología—

Yasumoto ADACHI*

Centro de inspección de carne Hayakita de la prefectura de Hokkaido

Resumen

Los datos de inspección de carne resumen e integran los resultados de las inspecciones realizadas en mataderos por veterinarios oficiales y centros de inspección de carne de gobiernos locales. Si bien estos datos se han utilizado en encuestas e investigaciones y se han transmitido a los productores para mejorar la higiene en la producción cárnica, se han reportado pocos casos en los que se haya realizado algo más que enumerar o dibujar gráficos de los datos de inspección de carne. Sin embargo, es difícil determinar objetivamente si las condiciones de cría del ganado tienden a mejorar o empeorar con base en la enumeración de cifras o la cantidad de cambio en los gráficos. Por lo tanto, se necesitan métodos estadísticos que proporcionen criterios en los que se basen las decisiones de productores, veterinarios y administradores. El análisis de series temporales es un método adecuado para analizar datos de inspección de carne, ya que comprende datos secuenciales de series temporales. Dado que el análisis de series temporales implica diversos métodos, para analizar los datos de inspección de carne es necesario seleccionar un método adecuado basado en la distribución estadística de los datos. Por lo tanto, los objetivos del presente estudio fueron identificar el método óptimo para utilizar correctamente múltiples modelos según la distribución de datos y analizar datos con diferentes tipos de distribuciones de forma exhaustiva.

Se llevaron a cabo investigaciones para obtener las condiciones favorables para que el modelo SARIMA y el modelo de dos partes detecten anomalías en la tasa y el número de condenas. Quedó claro que el modelo SARIMA es adecuado para analizar datos de tasa de condena que no se desvían excesivamente alrededor del 0% o el 100%, ya que se supone que la tasa de condena transformada logit tiene una distribución normal. Nuestros resultados también mostraron que un modelo de dos partes con regresión autoexponencial puede manejar adecuadamente datos que involucran un número excesivo de ceros. Por lo tanto, el presente estudio allana el camino para permitir proporcionar información administrativa sobre diversas enfermedades basada en criterios objetivos utilizando el modelo SARIMA para enfermedades en las que los datos rara vez contienen ceros y el modelo de dos partes para enfermedades en las que los datos contienen muchos ceros.

[Introducción]

El ganado ingresado al matadero es sometido a una inspección de sacrificio por parte de la Estación de Inspección Sanitaria de Carnes.

Contacto: Yasuki Adachi*

Estación de Inspección Sanitaria de Carne de Hayakita, Hokkaido

695 Toasa, Abira-cho, Yufutsu-gun, Hokkaido 059 1433

Cada animal es inspeccionado por un miembro del personal.

La inspección detectó que había algún problema con el producto y se consideró que no era apto para el consumo.

En algunos casos se prohíbe el sacrificio, se prohíbe el despiece, se eliminan todos los animales o solo una parte de ellos.

Se adoptará una de las siguientes medidas:

Con el fin de promover la producción de carne higiénica, se deben recopilar datos sobre los resultados de las inspecciones de sacrificio.

Varios gobiernos locales están ejecutando proyectos para devolver el dinero a los productores que deseen recibirlo.

Estos proyectos se denominan proyectos de retorno de datos y proyectos de retroalimentación.

[Necesidad y desafíos del análisis estadístico de los resultados de la inspección de sacrificio]

Muchos laboratorios de inspección de higiene de la carne en todo el país están implementando programas de transferencia de datos. Sin embargo, la mayoría de los datos proporcionados consisten en listas de resultados de inspecciones de mataderos. Si bien algunos laboratorios procesan los datos, solo los muestran gráficamente a lo largo del tiempo. Sin embargo, las listas de datos brutos y los gráficos de líneas contienen variaciones debido a fenómenos biológicos, y centrarse únicamente en los datos brutos sin considerar estos efectos puede llevar a juicios erróneos. Por lo tanto, para que más personas utilicen eficazmente los datos de inspección de mataderos, se necesitan métodos estadísticos que proporcionen indicadores objetivos para determinar si hay un aumento o disminución significativo en la tasa de decomisos. El análisis de series temporales es un método de procesamiento estadístico para analizar secuencias de datos que surgen a lo largo del tiempo (datos de series temporales). Al estimar un modelo matemático basado en secuencias de datos pasadas, se pueden predecir los valores y distribuciones esperados futuros. Los resultados de la inspección de mataderos son datos de series temporales y pueden ser objeto de análisis de series temporales. Sin embargo, existen dos problemas al realizar análisis de series temporales de los resultados de la inspección de mataderos en programas de transferencia de datos. En primer lugar, las enfermedades comunes y las poco frecuentes no pueden procesarse con un solo método analítico debido a que sus distribuciones estadísticas difieren. En segundo lugar, los procedimientos de procesamiento de datos para el análisis de series temporales son demasiado engorrosos para que los inspectores de mataderos los realicen mensualmente. Estos problemas se solucionaron mediante el uso adecuado de dos métodos analíticos, el descubrimiento de un procedimiento sencillo que permite el modelado adecuado de series temporales y la automatización del procesamiento mediante computadores.

¿Qué es la función de autocorrelación?

La función de autocorrelación es un concepto fundamental en el análisis de series temporales. Antes de explicar el método de análisis, intentaremos explicar su importancia a partir de un coeficiente de correlación general. La Figura 1 muestra el coeficiente de correlación de una res sacrificada en una granja Q y vendida en el Centro de Saneamiento de Carnes de Higashimokoto en Hokkaido.

Esta figura muestra la tendencia en la tasa de decomiso debido a neumonía similar a la neumonía epidémica porcina (PEE) en cerdos analizados en un centro de pruebas con animales vivos. Si bien es difícil discernir algún patrón a partir de esta tendencia en la tasa de decomiso, si hay un ciclo de un año, existe la posibilidad de una correlación con la serie de datos de hace un año. Por lo tanto, calculamos la correlación entre los datos de la serie temporal de las tasas de decomiso mensuales, x_i , y los datos de la serie temporal de las tasas de decomiso de hace 12 meses, y ($y = x_{i-12}$). La Figura 2 muestra un diagrama de dispersión (A) utilizando datos de hace 12 meses y un diagrama de dispersión (B) utilizando datos de hace 18 meses como control. La tabla en la Figura 2 (A) muestra una

correlación con los datos de hace 12 meses a un nivel de significancia del 0,1%. La diferencia de tiempo entre los datos utilizados para examinar la correlación se denomina "lag". La función de retardo se puede obtener variando el retardo entre 1 y el número de muestras menos 1, y calculando el coeficiente de correlación para cada uno. La función creada con base en esta idea es la función de autocorrelación (ACF). La función de autocorrelación se obtiene mediante la siguiente ecuación (1), y su valor difiere ligeramente del coeficiente de correlación con los valores anteriores calculado en la Figura 2.

$$\rho(h) = \frac{\sum_{i=1}^{N-h} (x_i - \bar{x})(x_{i+h} - \bar{x})}{\sum_{i=1}^N (x_i - \bar{x})^2} \dots (1)$$

Aquí, h es el rezago, N es el número de muestras en los datos de la serie temporal, x_i es el valor de los datos de la serie temporal en el punto temporal i y $\bar{x}$ es el valor x promedio de los datos de la serie temporal. Utilizando la ecuación (1), se calculó el ACF para la tasa mensual de decomiso de pulmones debido a neumonía similar a SEP en cerdos producidos en la Granja Q y se mostró en la Figura 3. El gráfico de la Figura 3 muestra que el coeficiente de correlación alcanza valores máximos significativos en rezagos de 12 y 24 meses, lo que indica que la tasa de decomiso tiende a fluctuar en un ciclo de un año. El ACF tiene aplicaciones importantes además de confirmar la dependencia temporal de los datos de series temporales. Uno de los objetivos de este estudio es obtener un modelo de series temporales válido a partir de los datos de series temporales de los resultados de la inspección del sacrificio. Uno de los criterios de validez de un modelo de series temporales es la aleatoriedad de los residuos. Los residuos se obtienen restando el valor esperado calculado por el modelo de series temporales del valor observado en cada punto temporal. Si el modelo de series temporales es válido, los residuos serán una secuencia aleatoria de números sin autocorrelación. La ACF es un método para comprobar si los residuos son una secuencia de números aleatorios.




Figura 1. Tasas mensuales de eliminación de pulmones por neumonía similar a SEP en cerdos de la Granja Q (abril de 2003 a febrero de 2018)




Figura 2. Diagrama de dispersión y coeficiente de correlación de las tasas de sacrificio mensuales debido a neumonía similar a SEP en cerdos producidos en la Granja Q y los números de sacrificios mensuales en el pasado.

(A) Correlación con la tasa mensual de residuos 12 meses antes

(B) Correlación con la tasa de descarte mensual 18 meses antes




Figura 3. Función de autocorrelación (ACF) de las tasas mensuales de decomiso de pulmones debido a neumonía tipo SEP en cerdos producidos en la granja Q. Las líneas punteadas representan los límites de confianza del 95%.

De hecho, se crearon varios modelos de series de tiempo utilizando los datos de Farm Q. Entre ellos, el modelo A tuvo el mejor ajuste y el modelo B tuvo un peor ajuste que el A. Los residuos A y B se calcularon restando los valores esperados calculados utilizando dos modelos.

Se calculó el ACF y se muestra en la

Figura 4. En el gráfico de la Figura 4 (A), no hay rezagos que muestren un coeficiente de correlación significativo, pero en (B), hay múltiples rezagos que sí lo muestran. A partir de estos resultados, el Modelo A es adecuado, pero hay elementos en los residuos del Modelo B que no están suficientemente modelados.

Por lo tanto, se puede concluir que el Modelo B no es apropiado.

[Modelo ARMA]

El modelo de media móvil integrada autorregresiva estacional (SARIMA)5 combina un modelo de media móvil autorregresiva (ARMA) para modelar procesos estacionarios, procesamiento diferencial para convertir procesos no estacionarios en estacionarios y un componente estacional para modelar fluctuaciones periódicas. El modelo ARMA central es la suma de un modelo autorregresivo (AR) y un modelo de media móvil (MA). A continuación, se explica brevemente por qué los diversos datos de series temporales observados en la práctica pueden expresarse mediante una fórmula matemática breve (o su suma) que consiste en la suma de un modelo AR y un modelo MA. La ecuación (2) es la fórmula para el modelo MA de primer orden más simple (denominado modelo MA(1)).

$$y_t = m + \theta a_{t-1} + a_t, \quad a_t \sim N(0, \sigma^2) \dots (2) \text{ Aquí,}$$

yi es el valor de los datos de la serie temporal en el tiempo t, m es una constante, at es el error en el tiempo t (la diferencia entre el valor observado y el valor esperado), y $a_t \sim N(0, \sigma^2)$ indica que el error se distribuye normalmente con un valor esperado de 0 y una varianza de σ^2 . En la ACF de los datos que siguen el modelo MA(1), el valor del coeficiente de correlación p en el retardo 1 se puede calcular mediante la ecuación (3).

hacer.

$$\rho = \frac{\theta}{1 + \theta^2} \dots (3)$$

La ecuación (4) es un modelo MA de segundo orden (llamado modelo MA(2)).




Figura 4. ACF de los residuos de dos modelos creados a partir de datos mensuales de la tasa de decomiso pulmonar por neumonía similar a SEP en cerdos producidos en la granja Q. (A) Residuos del modelo A
(B) Residuos para el modelo B. Las líneas punteadas representan los límites de confianza del 95%.




Figura 5. ACF de datos simulados del modelo MA
(A) Modelo MA(1)
(B) Modelo MA(2)

(Esta es la fórmula:

$y_t = m + \theta_1 a_{t-1} + \theta_2 a_{t-2} + a_t, \quad a_t \sim N(0, \sigma^2)$... (4) Este es el modelo MA(1) con un término de error añadido en el tiempo t-2. En la ACF de los datos que sigue el modelo MA(2), los coeficientes de correlación p1 y p2 para los retardos 1 y 2 pueden calcularse mediante las ecuaciones (5) y (6).

$$\rho_1 = \frac{\theta_1 + \theta_1 \theta_2}{1 + \theta_1^2 + \theta_2^2} \dots (5)$$

$$\rho_2 = \frac{\theta_2}{1 + \theta_1^2 + \theta_2^2} \dots (6)$$

La Figura 5 muestra el ACF calculado mediante la creación de datos de simulación e introduciendo los valores adecuados en los parámetros de las ecuaciones de los modelos MA(1) y MA(2). En general, los coeficientes de correlación para los rezagos 1 a q del modelo MA(q) pueden calcularse a partir de los coeficientes θ1 a θq del modelo MA(q) .

Esto significa que se puede crear un modelo con cualquier ACF utilizando el modelo MA(q) estableciendo adecuadamente los coeficientes, pero dependiendo del patrón de ACF, la fórmula del modelo puede volverse infinitamente larga. A continuación, explicaremos el modelo AR. La ecuación (7) es de primer orden. Esta es la fórmula del modelo AR (también llamado modelo $y_t = m + \phi y_{t-1} + a_t, \quad a_t \sim N(0, \sigma^2)$ AR(1)): ... (7) donde φ es el coeficiente. La Figura 6 muestra la ACF de los datos simulados para el modelo AR(1). A diferencia del modelo MA(1), el coeficiente de correlación disminuye monótonamente al aumentar el rezago. La ecuación (7) también se cumple para yt-1... yt-k , y al sustituir sucesivamente las ecuaciones para yt-1... yt-k en la ecuación (7), se obtiene la ecuación (8).
puede ser

$$y_t = m(1 + \phi + \dots + \phi^k) + \phi^k y_{t-k} + a_t + \sum_{i=1}^k \phi^i a_{t-i} \dots (8)$$

Debido a la restricción en la estacionariedad del modelo AR (no discutida en este documento), $|\phi| < 1$, entonces cuando $k \rightarrow \infty$, $\phi^k y_{t-k} \rightarrow 0$. En este caso, la ecuación (8) se convierte en la ecuación para el modelo $MA(\infty)$. En otras palabras, el modelo $AR(1)$ es un modelo $MA(\infty)$. Aunque no se muestra aquí, también se puede deducir a la inversa que el modelo $MA(1)$ es un modelo $AR(\infty)$. En otras palabras, un modelo que no se puede expresar usando una ecuación larga con el modelo MA o el modelo AR solo se puede expresar con una ecuación corta combinando el modelo AR y el modelo MA . Estas características del modelo $ARMA$ son la razón por la cual el modelo $ARMA$ se usa como el núcleo del modelo $SARIMA$. El modelo $SARIMA$ es un modelo $ARMA$ que agrega procesamiento diferencial para convertir un proceso no estacionario en un proceso estacionario y un componente estacional. Por limitaciones de espacio, no profundizaremos en el procesamiento diferencial ni en los componentes estacionales. En los últimos años, se han utilizado los modelos $SARIMA$.




Figura 5. ACF de los datos simulados del modelo AR

Se han publicado muchos libros de texto.

[Análisis de series temporales de datos de inspección de mataderos
utilizando el modelo $SARIMA$]

Para enfermedades que se observan consistentemente en cada momento, es decir, enfermedades cuya tasa de condenas se mantiene consistentemente por encima de 0, los datos mensuales de la tasa de condenas transformados logit pueden analizarse mediante un modelo $SARIMA$. Al utilizar datos mensuales, la distribución prevista para este mes se calcula mediante un modelo $SARIMA$ con parámetros estimados a partir de los datos del mes anterior. Al examinar si la tasa de condenas de este mes se encuentra dentro del rango del intervalo de predicción, es posible determinar si ha habido un aumento o una disminución significativos en dicha tasa.

Los modelos $SARIMA$ tienen dos tipos de parámetros: parámetros de tipo y parámetros de coeficiente. Mientras que los parámetros de coeficiente pueden calcularse mediante la estimación de máxima verosimilitud, los parámetros de tipo requieren una validación repetida de múltiples valores tentativos. Finalmente, se selecciona el modelo con el mejor Criterio de Información de Akaike (AIC), un índice de ajuste del modelo. Realizar fielmente este proceso repetitivo para todos los productores y enfermedades sujetos a la reducción de datos requeriría una enorme cantidad de tiempo, incluso si todo el proceso estuviera automatizado. Por lo tanto, omitimos el proceso de validación y realizamos la selección de modelos únicamente con base en el AIC. Como resultado, desarrollamos un sistema que selecciona modelos únicamente con base en el AIC, calcula intervalos de predicción basados en los modelos y los muestra gráficamente. Este sistema fue capaz de procesar 20 productores x 10 enfermedades/órganos en un tiempo práctico (aproximadamente medio día).




Figura 6. Distribución de descartes mensuales de hígado por equinococosis en cerdos de la Granja X (A) y distribución de números aleatorios de Poisson generados con los valores de los parámetros establecidos como media de (A) (B).

[Modelo de dos partes]

Se suele pensar que los fenómenos naturales discretos siguen una distribución de Poisson. Sin embargo, al comparar el histograma del número mensual de hígados descartados por equinococosis en la Granja X (Figura 6(A)) con el histograma de números aleatorios de Poisson, cuyo promedio de descartes es el valor esperado (Figura 6(B)), el histograma del número de descartes difiere significativamente de la distribución de Poisson, y el exceso de datos cero resulta en una sobredispersión, con una varianza mayor que la media.

Los modelos de dos partes son adecuados para modelar datos que están sobredispersos debido a la inclusión de muchos ceros. El modelo de dos partes es un modelo híbrido de dos modelos. Primero, se utiliza una distribución binomial para determinar si una variable aleatoria sigue una distribución definida por cero o discreta. Si la variable aleatoria no es definida por cero, la segunda distribución discreta la determina. Un modelo en el que la segunda distribución discreta no incluye el cero se denomina modelo de obstáculo8), y uno que sí lo incluye se denomina distribución inflada por cero9) . La distribución de Poisson o distribución binomial negativa se utiliza a menudo como la segunda distribución

discreta. La ecuación (9) es la ecuación para la distribución binomial negativa inflada por cero para modelar los datos.

$$P(Y_t = y_t) = \begin{cases} \omega_t + (1 - \omega_t)f(0) & (y_t = 0) \\ (1 - \omega_t)f(y_t) & (y_t > 0) \end{cases} \dots(9)$$

dónde

$$f(y_t) = \frac{\Gamma(\theta+y_t)}{\Gamma(\theta)\Gamma(y_t+1)} \left(\frac{\theta}{\theta+\lambda_t}\right)^\theta \left(\frac{\lambda_t}{\theta+\lambda_t}\right)^{\lambda_t}$$

La ecuación (f yt) es la ecuación para la distribución binomial negativa, donde wt es la probabilidad de que la distribución binomial determine cero en el tiempo t (llamado parámetro inflado a cero), λt es el valor esperado en el tiempo t y θ es el parámetro de dispersión.

Investigaciones anteriores sobre modelos de dos partes que utilizan datos de series de tiempo7) han utilizado la autorregresión. Para limitar el rango de variación del parámetro inflado a cero ω y el valor esperado λ, se aplican funciones de enlace como logit o logaritmo, y la transformación logarítmica de yt-i en el lado derecho se aplica para que coincida con la dimensión de λ en el lado izquierdo para formar un modelo autorregresivo, como se muestra en la ecuación (10) a continuación. Sin embargo, si el valor observado es cero, yt-i no se puede transformar logarítmicamente y la ecuación (10) no se puede definir.

$$\log \lambda_t = \beta_0 + \sum_{i=1}^p \beta_i \log y_{t-i} \dots(10)$$

Aquí, β0 es el valor de la intersección, βi es el coeficiente del término de regresión y p es el orden del término de regresión.

El manejo de valores cero es un problema no solo en los modelos de dos partes, sino también en el modelado de datos de conteo.6) En tales casos, el problema se ha resuelto agregando un número pequeño como 0,1 al cero.11)

[Modelo de auto]

En el automodelo ideado por Besag4) para el análisis espacial utilizando campos aleatorios de Markov en el campo de la ecología , la frecuencia del evento Yj se regresiona sin transformación logarítmica en la expectativa ligada al logaritmo λ, como se muestra en la ecuación (11) .

$$\lambda_i = E[Y_i|\{Y_j:j \neq i\}] \qquad \log \lambda_i = \beta_0 + \sum_{j \in N(i)} Y_j \beta_{ij} \dots(11) \text{ Besag}$$

limitó el coeficiente β a números negativos para evitar que λ alcanzara un valor muy elevado, pero Augustin et al. 3) informaron que si el valor del coeficiente β es adecuado, no hay problema incluso con correlación positiva, y en caso de sobredispersión, también puede utilizarse para una distribución binomial negativa. Por lo tanto, decidimos extrapolar este automodelo a un modelo de series temporales.

[Análisis de series temporales utilizando modelos de dos partes]

Para realizar un análisis de series de tiempo del número de cerdos sacrificados debido a enfermedades raras como la equinococosis porcina, la Estación de Inspección de Higiene de la Carne Higashimokoto en Hokkaido extrapola un automodelo a la ecuación de regresión para wt y λt en la ecuación (9) y utiliza las siguientes ecuaciones (12) y

$$\log \lambda_t = \beta_0 + \sum_{i=1}^p \beta_i y_{t-i} \dots(12)$$

$$\text{logit}(\lambda_t) = \gamma_0 + \sum_{i=1}^p \gamma_i y_{t-i} \dots(13)$$

El modelo de dos partes, que extrapoló este automodelo, resultó ser un método que permitía obtener modelos válidos sin la transformación logarítmica de datos con ceros.2) Por lo tanto, creamos un programa informático para procesar automáticamente el modelado y construimos un sistema que pudiera procesarlo en un plazo práctico. Antes de utilizar este modelo, se notificaba a los productores cuyos decomisos debido a enfermedades zoonóticas, como la equinococosis porcina y la micobacteriosis atípica porcina, superaban ciertos umbrales. Estos umbrales eran i) una tasa de decomiso (parcial o total) superior al 1% o ii) uno o más decomisos parciales o totales ocurridos durante tres o más meses consecutivos. Estos umbrales previos carecían de fundamento. La OMS10) define un brote como «una ocurrencia que excede el número de casos normalmente esperado», por lo que el estándar debería basarse en valores esperados determinados mediante métodos estadísticos, en lugar de criterios arbitrarios. Conforme a las normas anteriores, para los pequeños productores que faenaban menos de 100 cabezas al mes, se proporcionaba información cada mes en que se descartaban una o más cabezas según el criterio i), mientras que para los grandes productores, los casos que excedían el criterio i) eran poco frecuentes, y la información se proporcionaba tres meses después del primer incidente según el criterio ii). Sin embargo, al realizar juicios utilizando un modelo de series de tiempo, es posible proporcionar in

Además, el número de residuos que se desechan está disminuyendo.

A medida que se acerca el final de la pandemia, el número de descartes cae por debajo del valor esperado.

No se envía información mensual a los grandes productores.

Se convirtió.

resumen

En la Estación de Inspección de Higiene de la Carne de Higashimokoto en Hokkaido, el modelo SARIMA

El sistema analítico procesa los resultados de la inspección de sacrificio y los envía a los productores que desean recibirlos.

Además, se ha desarrollado un sistema de análisis que utiliza un modelo de dos partes.

La OMS ha estado investigando el brote de equinococosis porcina y micobacteriosis atípica.

El laboratorio utiliza este sistema como sistema de detección de granjas lacustres sospechosas.

Estamos proporcionando información a las granjas donde se ha detectado la enfermedad.

Los resultados de esta investigación se han publicado en colaboración con la Unidad de Epidemiología Veterinaria de la Universidad Rakuno Gakuen.

Esto se logró mediante una investigación conjunta.

Referencias

1) Yasuki Adachi y Kohei Makita: Modelo de media móvil integrada autorregresiva estacional
Análisis de series temporales de datos de inspección de matanza Revista de la Sociedad Japonesa de Estadística Veterinaria
utilizando el NIMS. 68, 189-197, 2015.

2) Adachi, Y. y Makita, K.: Análisis de series temporales basado en modelos de dos partes
para datos de recuento cero excesivos para detectar brotes de equinococosis porcina
en granjas durante las inspecciones de carne. Prev. Vet. Med., 148, 49-57, 2017.

3) Augustin, NH, McNicol, J. y Marriott, CA: Uso del modelo auto-Poisson truncado para
recuentos correlacionados espacialmente

de la vegetación. J. Agric. Environ. Stat., 11, 1-23, 2006.

4) Besag, J.: Interacción espacial y análisis estadístico de sistemas reticulares. JR Stat. Soc.
Series B. Stat. Methodol., 36, 192-236, 1974.

5) Box, GEP y Jenkins, GM: Análisis de series de tiempo: pronóstico y control, ed. rev.,
Holden-Day, San Francisco.

6) Briët, OJ, Amerasinghe, PH y Vounatsou, P.: General-
Modelos autorregresivos estacionales integrados de media móvil para datos de
recuento, con aplicación a series temporales de malaria con bajo número de casos.
PloS One, 8, e65781, 2013.

7) Huang, X. et al.: Casos de dengue importados, variación climática e incidencia de dengue
autóctono en Cairns, Australia.
PloS One, 8, e81887, 2013.

8) Lambert, D.: Regresión de Poisson con inflación de ceros, con aplicación a defectos de
fabricación. Technometrics, 34,
1-14, 1992.

9) Mullahy, J. : Especificación y pruebas en algunos modelos modificados
modelos de datos de conteo. J. Econom., 33, 341-365, 1986.

10) Oficina Regional de la Organización Mundial de la Salud para el Sudeste Asiático: Brotes
de enfermedades. Disponible en: http://www.searo.who.int/topics/disease_outbreaks/en/ (Consultado el 5 de septiembre de 2018)

11) Zeger, SL y Qaqish, B.: Modelos de regresión de Markov para series temporales: un
enfoque de cuasi-verosimilitud. Biometrics, 44,
1019-1031, 1988.