

第 53 回 獣医疫学会学術集会

VPCamp 共催シンポジウム “と畜検査員の役割—制度からちがう！日本と英国のと畜検査—”

講演 2

と畜検査結果の時系列分析法 —疫学を利用した食肉衛生のための新たなツール—

足立泰基*

北海道早来食肉衛生検査所

Time Series Analysis of Meat Inspection Result —A New Tool to Promote Hygienic Meat Production Based on Epidemiology—

Yasumoto ADACHI*

Hokkaido Prefecture Hayakita Meat Inspection Center

Summary

Meat inspection data summarize and integrate the results of meat inspections at slaughterhouses conducted by official veterinarians with local government meat inspection centers. Although meat inspection data has been utilized for surveys and research and fed back to producers to improve hygiene in meat production, few cases have been reported in which anything more than listing or drawing graphs of meat inspection data is performed. However, it is difficult to determine objectively whether livestock breeding conditions tend to become better or worse based on the enumeration of figures or quantity of change in graphs. That is, statistical methods that provide criteria on which the decisions made by producers, veterinarians, and administrators are based are needed. Time series analysis is a suitable method to analyze meat inspection data as it comprises sequential time series data. Since time series analysis involves a variety of methods, to analyze meat inspection data, it is necessary to select a proper method based on the statistical distribution of data. Therefore, the purposes of the present study were to identify the optimal method for using multiple models properly according to the distribution of data and to analyze data with different types of distributions comprehensively.

Investigations were carried out to obtain the favorable conditions for the SARIMA model and two-part model to detect anomalies in the condemnation rate and number. It became clear that the SARIMA model is suitable for analyzing condemnation rate data that do not deviate excessively around 0% or 100%, as the logit-transformed condemnation rate is assumed to be normally distributed. Our results also showed that a two-part model with autoexponential regression can adequately deal with data involving an excessive number of zeros. Therefore, the present study paves the way to enable providing administrative information regarding various diseases based on objective criteria using the SARIMA model for diseases in which the data rarely contain zeros and the two-part model for diseases in which the data contain many zeros.

【はじめに】

と畜場に搬入された家畜は、食肉衛生検査所のと畜検査

連絡先：足立泰基*

北海道早来食肉衛生検査所

〒059-1433 北海道勇払郡安平町遠浅 695 番地

員によって一頭ずつ検査される。疾病にかかり、若しくは異常があり、食用に供することができないと検査で認められた等々は、と殺禁止・解体禁止・全部廃棄・一部廃棄のいずれかの措置が取られる。

衛生的な食肉生産を促進するため、と畜検査結果のデータを希望する生産者に還元する事業が複数の自治体で行わ

れており、これらの事業は、データ還元事業やフィードバック事業などの名前で呼ばれている。

【と畜検査結果の統計学的分析の必要性和課題】

全国の多数の食肉衛生検査所でデータ還元事業が実施されているが、還元されているデータは、と畜検査結果の羅列が大半であり、一部の食肉衛生検査所ではデータの加工を行っているものの、経時変化のグラフ表示に留まっている。しかし、生データの数値の羅列や折れ線グラフ表示に現れる数値の増減には生物学的現象が示すばらつき等が含まれており、それらの効果を考慮せずに生データの増減のみに着目すると判断を誤る可能性がある。したがって、と畜検査データをより多くの者が有効に利用するためには、廃棄率の有意な増減の有無を判断するための客観的な指標を与える統計学的手法が必要である。

時系列分析は、時間とともに出現するデータの列（時系列データ）を分析するための統計学的処理方法であり、過去のデータの列をもとに数学モデルを推定することにより将来の期待値と分布を予測することができる。と畜検査結果は時系列データであり、時系列分析の対象となりうる。

と畜検査結果の時系列分析をデータ還元事業で行うには、2つの問題点がある。1つは、常時見られる疾病と稀に見られる疾病は、統計学的分布が同じではないために一つの分析法で処理できないことであり、もう一つは、時系列分析のデータ処理手順は、と畜検査員が毎月行うには煩雑すぎることである。そこで、これらの問題点を、2つの分析法を使い分けることと、妥当な時系列モデリングが可能かつ簡便な手順を見出し、コンピュータによって処理を自動化することにより解決した。

【自己相関関数とは】

自己相関関数は、時系列分析を行う上で非常に重要な概念であり、分析方法を解説するに先立ち、一般的な相関係数からのアプローチにより自己相関関数の重要性を解説することを以下に試みる。

図1に、ある農場Qで生産され、北海道東藻琴食肉衛

生検査所で検査された豚の豚流行性肺炎（SEP）様肺炎による廃棄率の推移を示す。この廃棄率の推移からは規則性を読み取ることは難しいが、仮に1年周期の変動があるならば、1年前のデータ列と相関性がある可能性がある。そこで、毎月の廃棄率の時系列データ x_i と12か月前の廃棄率の時系列データ $y_i (=x_{i-12})$ の相関を計算した。図2に、12か月前データを用いた散布図（A）と、対照として18か月前のデータを用いた散布図（B）を示す。図2（A）の表より12か月前のデータと有意水準0.1%で相関があることがわかる。

相関を調べるデータ間の時間差を「ラグ」と呼ぶ。ラグを1から順に標本数-1まで変化させ、それぞれの相関係数を計算することにより、ラグの関数を得ることができる。このような考え方で作り出された関数が自己相関関数（ACF：Auto Correlation Function）である。自己相関関数は、以下の（1）式により与えられ、図2で計算した過去の値との相関係数とは少し異なる値となる。

$$\rho(h) = \frac{\sum_{i=1}^{N-h} (x_i - \bar{x})(x_{i+h} - \bar{x})}{\sum_{i=1}^N (x_i - \bar{x})^2} \quad \dots (1)$$

ここで、 h はラグ、 N は時系列データの標本数、 x_i は i 時点における時系列データの値、 $\bar{x}$ は時系列データの平均値を示す。（1）式を用いてQ農場生産豚のSEP様肺炎による肺の月別廃棄率のACFを計算し、図3に示す。

図3のグラフには、ラグが12か月および24か月のときに相関係数が有意な極大値をとることから、廃棄率が1年周期の増減を繰り返す傾向があることがわかる。ACFにはこの例のような時系列データの時間依存性を確認することとは別に、重要な用途がある。

本研究の目的の一つは、と畜検査結果の時系列データから妥当な時系列モデルを得ることである。時系列モデルの妥当性の一つに、残差の無作為性がある。残差とは、各時点の観測値から時系列モデルで計算された期待値を差し引いたものであり、時系列モデルが妥当であれば、残差は、自己相関性のない無作為な数字の列となる。ACFは、残差が無作為な数字の列かどうかを確認するための方法の一つである。




図1 Q農場生産豚におけるSEP様肺炎による肺の月別廃棄率の推移（2003年4月～2018年2月）




図 2 Q 農場生産豚の SEP 様肺炎による肺の月別廃棄率と過去の月別廃棄数の散布図と相関係数
 (A) 12 か月前の月別廃棄率との相関
 (B) 18 か月前の月別廃棄率との相関




図 3 Q 農場生産豚の SEP 様肺炎による肺の月別廃棄率の自己相関関数 (ACF)
 点線は、95% 信頼限界を表す。

実際に Q 農場のデータを用いて多数の時系列モデルを作成し、その中でモデルのあてはまりが最もよかったモデル A と、A よりもあてはまりが劣っているモデル B の 2 つのモデルで計算した期待値を差し引いた残差 A と B の ACF を計算し、図 4 に示す。

図 4 (A) のグラフには、有意な相関係数を示すラグがないが、(B) には有意な相関係数を示すラグが複数存在している。これらの結果より、モデル A は妥当であるが、モデル B の残差にモデル化が十分ではない要素がみられ

ることからモデル B は妥当ではないと判断できる。

【ARMA モデル】

季節自己回帰和分移動平均 (SARIMA) モデル⁵⁾ は、定常過程をモデリングする自己回帰移動平均 (ARMA) モデル、非定常過程を定常過程に変換するための差分処理と周期変動をモデリングするための季節要素を組み合わせたものである。核となる ARMA モデルは、自己回帰 (AR) モデルと移動平均 (MA) モデルの和である。実際に観測される多様な時系列データがなぜ AR モデルと MA モデルの和からなる短い数式 (あるいはその和分) によって表現されるのか、その理由を以下に簡単に説明する。

(2) 式は、最も簡単な一次の MA モデル (MA (1) モデルと呼ばれる) の式である。

$$y_t = m + \theta a_{t-1} + a_t, \quad a_t \sim N(0, \sigma^2) \quad \cdots (2)$$

ここで、 y_t は t 時点における時系列データの値、 m は定数、 a_t は t 時点における誤差 (観測値と期待値の差) を表し、 $a_t \sim N(0, \sigma^2)$ は誤差が、期待値 0 分散 σ^2 で正規分布することを表している。MA (1) モデルに従うデータの ACF では、ラグ 1 の相関係数の値 ρ は、(3) 式により計算できる。

$$\rho = \frac{\theta}{1+\theta^2} \quad \cdots (3)$$

(4) 式は、2 次の MA モデル (MA (2) モデルと呼ばれ




図 4 Q 農場生産豚の SEP 様肺炎による肺の月別廃棄率データから作成した 2 つのモデルの残差の ACF
 (A) モデル A の残差
 (B) モデル B の残差
 点線は、95% 信頼限界を表す。




図 5 MA モデルのシミュレーションデータの ACF
 (A) MA (1) モデル
 (B) MA (2) モデル

る) の式である。

$$y_t = m + \theta_1 a_{t-1} + \theta_2 a_{t-2} + a_t, \quad a_t \sim N(0, \sigma^2) \quad \cdots (4)$$

MA (1) モデルに、 $t-2$ 時点の誤差項が追加されたものであり、MA (2) モデルに従うデータの ACF では、ラグ 1 とラグ 2 の相関係数の値 ρ_1, ρ_2 は (5) 式および (6) 式により計算できる。

$$\rho_1 = \frac{\theta_1 + \theta_1 \theta_2}{1 + \theta_1^2 + \theta_2^2} \quad \cdots (5)$$

$$\rho_2 = \frac{\theta_2}{1 + \theta_1^2 + \theta_2^2} \quad \cdots (6)$$

これら MA (1) および MA (2) モデルの式のパラメータに適当な数値を入れてシミュレーションデータを作成し、ACF を計算したものを図 5 に示す。

一般的に MA (q) モデルのラグ 1~ q の相関係数は、MA (q) モデルの係数 $\theta_1 \sim \theta_q$ から計算できる。このこと

は、係数を適当に定めることにより任意の ACF を有するモデルを MA (q) モデルによって作成できるが、ACF のパターンによっては、モデル式が無限に長くなることを意味している。

次に、AR モデルについて説明する。(7) 式は、1 次の AR モデル (AR (1) モデルと呼ばれる) の式である。

$$y_t = m + \phi y_{t-1} + a_t, \quad a_t \sim N(0, \sigma^2) \quad \cdots (7)$$

ここで、 ϕ は、係数である。図 6 に AR (1) モデルのシミュレーションデータの ACF を示す。MA (1) モデルと異なり、相関係数がラグの増加とともに単調減少する。

(7) 式は、 $y_{t-1} \cdots y_{t-k}$ についても同様に成り立ち、 $y_{t-1} \cdots y_{t-k}$ に関する式を (7) 式に逐次代入すると (8) 式が得られる。

$$y_t = m(1 + \phi + \cdots + \phi^k) + \phi^k y_{t-k} + a_t + \sum_{i=1}^k \phi^i a_{t-i} \quad \cdots (8)$$

AR モデルの定常性に関する制約（本稿では述べない）から $|\phi| < 1$ であるため、 $k \rightarrow \infty$ のとき $\phi^k y_{t-k} \rightarrow 0$ となる。このとき (8) 式は、MA (∞) モデルの式となっている。すなわち AR (1) モデルは MA (∞) モデルである。

ここには示さないが、逆に MA (1) モデルは AR (∞) モデルであることも同様に導くことができる。すなわち、MA モデルもしくは AR モデル単独では長大な式を用いなければ表現できないモデルを AR モデルと MA モデルの結合により、短い式で表すことができるのである。このような ARMA モデルの特性こそが、SARIMA モデルの核として ARMA モデルが用いられる理由である。

非定常過程を定常過程に変換するための差分処理と、季節要素を ARMA モデルに付加したものが SARIMA モデルである。差分処理と季節要素については紙面の関係もあり、ここでは詳述しない。近年では SARIMA モデルを取り扱

う多数の教本が出版されている。

【SARIMA モデルによると畜検査データの 時系列分析法】

各時点で常時見られる疾病、すなわち廃棄率の時系列データが常時 0 を上回る疾病であれば、ロジット変換した毎月の廃棄率データを SARIMA モデルで分析することができる。月別データを用いる場合、前月までのデータを用いてパラメータ推定した SARIMA モデルで今月の予測分布を計算し、予測区間の範囲内に今月の廃棄率があるかどうかを検討することにより、今月の廃棄率に有意な増減があったかどうかを判定することができる。

SARIMA モデルのパラメータにはタイプパラメータと係数パラメータの 2 種類がある。このうち係数パラメータは最尤推定計算で求めることができるが、タイプパラメータは、仮の値を決めたのちに複数の妥当性確認を行うという作業を繰り返し行い、最後にモデルのあてはまりの良さの指標である赤池情報量基準 (AIC) が最適のものが選択される。上記の繰り返し作業を、データ還元対象となる全ての生産者・疾病で忠実にを行うと、すべての作業をプログラムにより自動化しても、莫大な時間がかかる。

そこで、妥当性確認を省略し、AIC のみでモデル選択を行ったところ、98% (39/40) のモデルが妥当性を満たしていた¹⁾。この結果に基づき、AIC のみでモデルを選択し、モデルに基づいた予測区間を計算してグラフ表示するシステムを構築したところ、実用的な所要時間 (20 生産者 × 10 疾病・臓器を半日程度) で処理可能であった。




図 5 AR モデルのシミュレーションデータの ACF




図 6 農場 X 産肉豚のエキノコックス症による肝臓の月別廃棄数の分布 (A) と、パラメータの値を (A) の平均値として発生させたポアソン乱数の分布 (B)

【Two-part モデル】

離散的な自然現象はポアソン分布に従うことが多いと考えられている。しかし、ある農場 X におけるエキノコックス症による肝臓の月別廃棄数のヒストグラム（図 6 (A)）と、平均廃棄数を期待値とするポアソン乱数のヒストグラム（図 6 (B)）を比較すると、廃棄数のヒストグラムはポアソン分布とひどく違っており、過剰なゼロデータにより、平均よりも分散の値が大きい過分散となる。

Two-part モデルは、このような、多数のゼロを含むために過分散となっているデータのモデリングに適している。Two-part モデルは、2つのモデルの混合モデルであり、最初に確率変数がゼロ確定か離散分布に従うかの振り分けを二項分布によって行い、ゼロ確定でなければ2つめの離散分布によって確率変数が決定されるというモデルである。2つめの離散分布の確率変数にゼロを含まないものをハードルモデル⁸⁾と呼び、含むものをゼロ過剰分布⁹⁾と呼んでいる。2つめの離散分布には、ポアソン分布または負の二項分布がよく用いられる。

(9) 式は、ゼロ過剰負の二項分布の式である。

$$P(Y_t = y_t) = \begin{cases} \omega_t + (1 - \omega_t)f(0) & (y_t = 0) \\ (1 - \omega_t)f(y_t) & (y_t > 0) \end{cases} \quad \cdots (9)$$

ここで

$$f(y_t) = \frac{\Gamma(\theta + y_t)}{\Gamma(\theta)\Gamma(y_t + 1)} \left(\frac{\theta}{\theta + \lambda_t} \right)^\theta \left(\frac{\lambda_t}{\theta + \lambda_t} \right)^{\lambda_t}$$

$f(y_t)$ の式は、負の二項分布の式であり、 ω_t は、二項分布により t 時点でゼロが確定する確率であり（ゼロ過剰パラメータと呼ぶ）、 λ_t は t 時点における期待値であり、 θ は分散パラメータである。

時系列データを用いた two-part モデルの先行研究⁷⁾では、自己回帰が用いられている。ゼロ過剰パラメータ ω と期待値 λ の変域を制限させるため、ロジットや対数などのリンク関数を作用させ、自己回帰モデルとなるよう左辺の λ と次元を合わせるために右辺の y_{t-i} を対数変換したものを下に示す (10) 式のように回帰させることになる。しかし、観測値がゼロの場合は y_{t-i} を対数変換できず、(10) 式を定義できない。

$$\log \lambda_t = \beta_0 + \sum_{i=1}^p \beta_i \log y_{t-i} \quad \cdots (10)$$

ここで、 β_0 は切片の値、 β_i は回帰項の係数、 p は回帰項の次数を表す。

Two-part モデルに限らず、カウントデータのモデリングではゼロ値の取り扱いが問題となる⁶⁾。このような場合、0.1 などの小さな数を 0 に加える方法により対応されてきた¹¹⁾。

【オートモデル】

生態学分野におけるマルコフ確率場を用いた空間解析のために、Besag⁴⁾ が考案したオートモデルでは、(11) 式のように、対数リンクされた期待値 λ に対して対数変換せず

$$\lambda_i = E[Y_i | \{Y_j; j \neq i\}] \quad \log \lambda_i = \beta_0 + \sum_{j \in N(i)} Y_j \beta_{ij} \quad \cdots (11)$$

Besag は、 λ が巨大な値にならないよう、係数 β を負の数に限定していたが、Augustin ら³⁾ は、係数 β の値が適切であれば、正の相関でも問題はなく、過分散の場合には、負の二項分布にも使用できることを報告している。そこで、このオートモデルを時系列モデルに外挿することにした。

【Two-part モデルによる時系列分析法】

豚のエキノコックス症などの稀に見られる疾病による廃棄数を時系列分析するために北海道東藻琴食肉衛生検査所では、(9) 式の ω_t と λ_t に関する回帰式にオートモデルを外挿し、次に示す (12) および (13) 式を用いてモデリングを行っている。

$$\log \lambda_t = \beta_0 + \sum_{i=1}^p \beta_i y_{t-i} \quad \cdots (12)$$

$$\text{logit}(\lambda_t) = \gamma_0 + \sum_{i=1}^p \gamma_i y_{t-i} \quad \cdots (13)$$

このオートモデルを外挿した two-part モデルは、ゼロを含むデータを対数変換せずに使用でき、妥当なモデルが得られる方法であることがわかった²⁾。そこで、モデリングを自動処理するための PC プログラムを作成し、実用的な所要時間で処理可能なシステムを構築した。

本モデルを使用する以前は、人獣共通感染症である豚エキノコックス症や豚非定型抗酸菌症による廃棄が一定の基準を超えた生産者に対して、その旨の情報提供を行っていた。その基準とは、i) 廃棄率（一部または全部）が 1% を超えるか、ii) 1 以上の一部または全部廃棄が 3 か月以上連続で認められることである。これらの従来の基準には根拠はない。WHO¹⁰⁾ は、アウトブレイクを「通常期待される発生数を超えて発生すること」と定義していることから、恣意的な基準ではなく、統計学的手法で求めた期待値を基準としなければならない。

従来基準では、100 頭/月未満をと畜している小規模生産者では、基準 i) に基づき 1 頭以上の廃棄があるすべての月で情報提供がなされ、大規模生産者では基準 i) を超えるケースは少なく、基準 ii) に基づき初発から 3 か月経過後に情報提供されるという問題があった。しかし、時系列モデルによる判定を行うことにより、従来の基準よりも早

く情報提供が可能となった。また、廃棄数が減少傾向となり、終息が近くなると廃棄数が期待値を下回るために、小規模生産者に毎月情報提供が送付されるということもなくなった。

【まとめ】

北海道東藻琴食肉衛生検査所では、SARIMA モデルの分析システムでと畜検査結果を処理して希望する生産者に還元している。また、Two-part モデルを用いた分析システムを豚エキノкокクス症および非定型抗酸菌症のアウトブレイク疑い農場の検出システムとして同検査所では使用しており、検出された農場に情報提供している。

なお、本研究成果は、酪農学園大学獣医疫学ユニットとの共同研究により得られたものである。

【参考文献】

- 1) 足立泰基, 蒔田浩平 : 季節自己回帰和分移動平均モデルによると畜検査データの時系列分析法. *日獣会誌*, **68**, 189-197, 2015.
- 2) Adachi, Y. and Makita, K. : Time series analysis based on two-part models for excessive zero count data to detect farm-level outbreaks of swine echinococcosis during meat inspections. *Prev. Vet. Med.*, **148**, 49-57, 2017.
- 3) Augustin, N.H., McNicol, J. and Marriott, C.A. : Using the truncated auto-Poisson model for spatially correlated counts of vegetation. *J. Agric. Environ. Stat.*, **11**, 1-23, 2006.
- 4) Besag, J. : Spatial Interaction and the statistical analysis of lattice system. *J. R. Stat. Soc. Series B. Stat. Methodol.*, **36**, 192-236, 1974.
- 5) Box, G.E.P. and Jenkins, G.M. : Time series analysis : forecasting and control, rev. ed., Holden-Day, San Francisco.
- 6) Briët, O.J., Amerasinghe, P.H. and Vounatsou, P. : Generalized seasonal autoregressive integrated moving average models for count data with application to malaria time series with low case numbers. *PloS One*, **8**, e65781, 2013.
- 7) Huang, X. et al. : Imported dengue cases, weather variation and autochthonous dengue incidence in Cairns, Australia. *PloS One*, **8**, e81887, 2013.
- 8) Lambert, D. : Zero-inflated Poisson regression, with an application to defects in manufacturing. *Technometrics*, **34**, 1-14, 1992.
- 9) Mullahy, J. : Specification and testing in some modified count data models. *J. Econom.*, **33**, 341-365, 1986.
- 10) World Health Organization regional office for South East Asia: Disease outbreaks. Available at : http://www.searo.who.int/topics/disease_outbreaks/en/ (Accessed September 5, 2018)
- 11) Zeger, S.L. and Qaqish, B. : Markov regression models for time series : a quasi-likelihood approach. *Biometrics*, **44**, 1019-1031, 1988.